



REPUBLIQUE ALGERIENNE DEMOCRATIQUE ET POPULAIRE
MINISTERE DE L'ENSEIGNEMENT SUPERIEUR ET DE LA
RECHERCHE SCIENTIFIQUE
UNIVERSITE SAAD DAHLEB BLIDA 1



RAPPORT MINI PROJET

Présenté dans le cadre du module Machine Learning – Semestre 2

FACULTE DES SCIENCES

DEPARTEMENT INFORMATIQUE

DOMAINE : MATHEMATIQUES ET INFORMATIQUE

FILIERE : INFORMATIQUE

Gestion du déséquilibre de classes pour l'analyse de sentiments en dialecte Algérien

Travail présenté par :

Mlle Ali el ouahed Feriel.

Encadré par :

Dr Soraya Cheriguene

Année universitaire : 2025/2026

TABLE DE MATIERE

Résumé

Introduction générale

CHAPITRE 1 : État de l'art — Déséquilibre de classes en NLP et TALN pour le dialecte algérien

1. Déséquilibre de classes en NLP

2. TALN pour le dialecte algérien (darija)

3. Présentation du corpus TWIFL

- Contexte et objectifs
- Composition du corpus
- Nettoyage du corpus
- Analyse descriptive
 - Longueur des tweets
 - Distribution des langues
 - Caractéristiques linguistiques
 - Analyse lexicale

CHAPITRE 2 : Méthodologie — Stratégies de gestion du déséquilibre de classes

1. Introduction

2. Baseline (DziriBERT sans rééquilibrage)

3. Modification de la fonction de perte

- Class Weighting
- Focal Loss
- Combinaison des deux

4. Rééquilibrage dans l'espace des embeddings

- SMOTE
- ADASYN

5. Back-Translation

6. Méthode Hybride (SMOTE partiel + Class Weighting)

CHAPITRE 3 : Implémentation et Réalisation

1. Introduction

2. Analyse du Baseline

3. Analyse de la stratégie 1 : Fonction de perte

- Class Weighting
- Focal Loss ($\gamma=1$, $\gamma=2$)
- Comparaison

4. Analyse de la stratégie 2 : Sur-échantillonnage

- SMOTE (total / partiel)
- ADASYN (total / partiel)
- Stratégie hybride

5. Analyse de la stratégie 3 : Back-Translation

- Taux d'augmentation (20%, 50%, 100%)
- Analyse des résultats
- Changements de sentiment

6. Évaluation finale et tableau comparatif

CHAPITRE 4 : Discussion

1. Analyse critique des résultats

2. Limites des méthodes

3. Comparaison des stratégies

4. Conclusion du chapitre

Conclusion générale

Perspectives

LISTE DES FIGURES

- **Figure 1** — Distribution des classes dans le corpus de 6000 tweets (Positive, Negative, Neutral)
- **Figure 2** — Distribution de la longueur des tweets par classe de sentiment (mots et caractères)
- **Figure 3** — Distribution des langues détectées dans le corpus de 6000 tweets
- **Figure 4** — Caractéristiques linguistiques par classe de sentiment (usage des emojis et code-switching)
- **Figure 5** — Nuages de mots par classe de sentiment (positif, négatif, neutre)
- **Figure 6** — Tableau récapitulatif des statistiques du corpus
- **Figure 7** — Évaluation finale — Baseline DziriBERT
- **Figure 8** — Matrices de confusion (baseline)
- **Figure 9** — Courbes précision-rappel par classe (baseline)
- **Figure 10** — Confusion Matrix : Stratégie 1 (Class Weighting)
- **Figure 11** — Matrice de confusion du modèle DziriBERT avec Focal Loss $\gamma=1$
- **Figure 12** — Matrice de confusion du modèle DziriBERT avec Focal Loss $\gamma=2$
- **Figure 13** — Évolution des métriques (Class Weighting + Focal Loss $\gamma=2$)
- **Figure 14** — Matrice de confusion (SMOTE total)
- **Figure 15** — Courbe précision-rappel (SMOTE total)
- **Figure 16** — Matrice de confusion (SMOTE partiel)
- **Figure 17** — Courbe précision-rappel (SMOTE partiel)
- **Figure 18** — Matrice de confusion (ADASYN total)
- **Figure 19** — Courbe précision-rappel (ADASYN total)
- **Figure 20** — Matrice de confusion (ADASYN partiel)
- **Figure 21** — Courbe précision-rappel (ADASYN partiel)
- **Figure 22** — Matrice de confusion Stratégie Hybride (CW + SMOTE partiel)
- **Figure 23** — Matrice de confusion — Back-Translation 20%
- **Figure 24** — Courbe précision-rappel — Back-Translation 20%
- **Figure 25** — Matrice de confusion — Back-Translation 50%
- **Figure 26** — Courbe précision-rappel — Back-Translation 50%
- **Figure 27** — Matrice de confusion — Back-Translation 100%
- **Figure 28** — Courbe précision-rappel — Back-Translation 100%
- **Figure 29** — Changements de sentiment

Résumé

Ce travail s'inscrit dans le cadre du module **Machine Learning** du Master 1 SD & TAL à l'Université USDB. L'objectif est d'étudier et de proposer des solutions au problème du **déséquilibre de classes** dans l'analyse de sentiments en dialecte algérien (darija). Ce corpus présente une distribution inégale des classes : les tweets **Positifs** sont majoritaires et faciles à détecter, tandis que les tweets **Neutral** et **Negative** sont minoritaires et plus difficiles à classifier.

Pour répondre à ce défi, plusieurs approches ont été mises en œuvre et comparées :

- **Baseline (CrossEntropy classique)**, servant de référence.
- **Class Weighting**, qui corrige le déséquilibre structurel entre les classes.
- **Focal Loss** avec différents paramètres γ ($\gamma=1$ et $\gamma=2$), qui réduit l'impact des exemples faciles et accentue l'apprentissage sur les exemples difficiles.
- **Combinaison Class Weighting + Focal Loss**, qui associe les deux stratégies pour maximiser l'équilibre entre les classes.
- **Techniques de rééchantillonnage et d'augmentation de données** (SMOTE, ADASYN, Back Translation), afin d'augmenter la représentativité des classes minoritaires.

Chaque configuration a été évaluée sur le **test set** à l'aide de métriques adaptées aux corpus déséquilibrés :

- **F1 macro** et **F1 par classe (Positive, Negative, Neutral)**
- **AUC-PR** (aire sous la courbe précision-rappel)
- **G-mean** (moyenne géométrique sensibilité $\times$ spécificité)

Les résultats ont été synthétisés dans un tableau comparatif, permettant d'analyser l'impact de chaque stratégie sur la performance globale et sur l'équilibre entre les classes.

I. Introduction générale

L'analyse de sentiments est une tâche clé du traitement automatique des langues (TAL), car elle permet de détecter et de catégoriser les opinions exprimées dans des textes. Dans le contexte des réseaux sociaux, cette analyse est particulièrement utile pour comprendre les tendances sociales, mesurer la satisfaction des utilisateurs ou encore détecter des discours haineux. Les plateformes comme Twitter ou Facebook produisent chaque jour des millions de messages, constituant une source précieuse pour les chercheurs et les entreprises.

Dans le cas du dialecte algérien (darija), cette tâche est encore plus complexe. Le darija est une langue vivante, riche et variée, mais elle souffre d'un manque de ressources numériques. Elle se caractérise par un mélange d'arabe dialectal, d'arabe standard, de français et parfois de berbère, avec une orthographe non standardisée (alphabet arabe ou latin, chiffres pour certains sons). Cette diversité rend difficile la constitution de corpus homogènes et l'entraînement de modèles robustes. De plus, le phénomène de **code-switching** (mélange de plusieurs langues dans un même tweet) et l'usage de l'**Arabizi** (écriture de l'arabe avec des caractères latins et des chiffres) compliquent encore davantage le traitement automatique.

Un des problèmes majeurs rencontrés dans ce domaine est le **déséquilibre de classes**. Dans les corpus de sentiments, certaines classes (comme *Positive*) sont largement représentées, tandis que d'autres (comme *Neutral* ou *Negative*) sont minoritaires. Dans le corpus TWIFL utilisé pour ce projet, l'exploration des données montre une distribution inégale entre les classes : la classe *Positive* représente plus de la moitié des tweets, alors que la classe *Neutral* ne dépasse pas 14 % dans le train set. Ce déséquilibre entraîne un biais d'apprentissage : le modèle apprend surtout à prédire la classe majoritaire et ignore les classes minoritaires.

Les conséquences sont multiples :

- Les classes minoritaires sont mal reconnues, ce qui réduit la fiabilité du modèle.
- Les métriques classiques comme l'accuracy donnent une impression trompeuse, car elles sont dominées par la classe majoritaire.
- Dans des applications réelles (analyse politique, satisfaction client, détection de discours haineux), ce biais peut fausser les résultats et mener à de mauvaises décisions.

Problématique

Comment concevoir et évaluer des méthodes de Machine Learning capables de **réduire l'impact du déséquilibre de classes** et d'**améliorer la reconnaissance des tweets minoritaires (Neutral et Negative)**, tout en maintenant de bonnes performances globales sur l'ensemble du corpus TWIFL ?

CHAPITRE 1 : État de l'art — déséquilibre de classes en NLP et TALN pour le dialecte algérien

1. Déséquilibre de classes en NLP

Le déséquilibre de classes est un problème récurrent en apprentissage automatique, particulièrement dans les tâches de classification de textes. Lorsqu'une classe est sur-représentée dans un corpus, les modèles tendent à privilégier cette classe au détriment des classes minoritaires. Ce phénomène entraîne un biais d'apprentissage et une baisse de performance globale, notamment sur les métriques équilibrées comme le **F1-macro** ou l'**AUC-PR**.

Stratégies classiques de rééquilibrage

- **Class Weighting** : pondération des classes dans la fonction de perte.
- **Focal Loss** : accentuation des exemples difficiles pour réduire l'impact des classes majoritaires.
- **Sur-échantillonnage** : duplication ou génération artificielle d'exemples minoritaires (SMOTE, ADASYN).
- **Data augmentation** : création de nouvelles données par paraphrases, traduction, ou perturbations lexicales (Back-Translation, synonymes, etc.).

2. TALN pour le dialecte algérien (darija)

Le traitement automatique du langage naturel (TALN) appliqué au dialecte algérien présente des défis spécifiques. Le darija est une langue vivante, non standardisée, qui combine plusieurs influences linguistiques.

Caractéristiques du darija

- **Mélange linguistique** : arabe dialectal, arabe standard, français, parfois berbère.
- **Orthographe non standardisée** : utilisation de l'alphabet arabe ou latin, chiffres pour certains sons (Arabizi).

- **Code-switching** : alternance entre arabe et français dans un même tweet.
- **Usage d'emojis et abréviations** : fréquents dans les réseaux sociaux.

Défis pour le TALN

- **Manque de ressources** : peu de corpus annotés disponibles pour le darija.
- **Variabilité orthographique** : difficulté à normaliser les données.
- **Absence de modèles pré-entraînés spécifiques** : nécessité d'adapter des modèles multilingues ou arabophones.

Travaux existants

- **DziriBERT** : premier modèle pré-entraîné spécifiquement pour le dialecte algérien, basé sur l'architecture BERT. Il constitue une avancée majeure mais reste limité par la taille et la diversité des corpus disponibles.
- **Corpus TWIFL** : ressource annotée pour l'analyse de sentiments en darija, intégrant la diversité linguistique des tweets algériens.

Importance du rééquilibrage

Dans le cas du darija, le déséquilibre de classes est accentué par la variabilité linguistique et la rareté des données. Les classes minoritaires (Neutral, Negative) sont particulièrement difficiles à reconnaître. Les stratégies de rééquilibrage deviennent donc essentielles pour améliorer la performance des modèles et garantir une analyse fiable des sentiments exprimés dans les réseaux sociaux algériens.

Conclusion de l'état de l'art

- Le **déséquilibre de classes** est un problème central en NLP, qui fausse les performances des modèles et limite leur applicabilité.
- Le **darija** présente des défis supplémentaires liés à sa diversité linguistique et au manque de ressources.
- Les travaux existants (DziriBERT, corpus TWIFL) offrent une base solide, mais nécessitent des stratégies de rééquilibrage pour améliorer la reconnaissance des classes minoritaires.

Présentation du corpus TWIFL

1. Contexte et objectifs

Le corpus TWIFL (Twitter Algerian Sentiment Corpus) a été conçu pour l'analyse de sentiments en dialecte algérien (darija). Il s'agit d'une ressource annotée collectée à partir de tweets publics, visant à pallier le manque de données disponibles pour le TALN appliqué au darija. Ce corpus est utilisé comme base expérimentale pour ce projet de gestion du déséquilibre de classes.

2. Composition du corpus

- **Taille totale** : 6000 tweets annotés.
- **Répartition en ensembles** :
 - Train : 3512 tweets
 - Validation : 753 tweets
 - Test : 753 tweets
- **Distribution des classes (train set)** :
 - Positive : 1820 (51,8 %)
 - Negative : 1210 (34,5 %)
 - Neutral : 482 (13,7 %)

Ratio de déséquilibre ≈ 2.1 ce qui confirme un **fort déséquilibre**.

Distribution des classes :			
Positive	:	2864 tweets	(47.7%)
Negative	:	1773 tweets	(29.5%)
Neutral	:	1363 tweets	(22.7%)
TOTAL	:	6000 tweets	
Classe majoritaire : Positive (2864 exemples)			
Classe minoritaire : Neutral (1363 exemples)			
Ratio de déséquilibre : 2.10x			
→ Conclusion : le corpus est MODÉRÉMENT déséquilibré (ratio = 2.10).			

Figure 1 — Distribution des classes dans le corpus de 6000 tweets (Positive, Negative, Neutral)

3. Nettoyage de base

- **Suppression des URLs et mentions** : ces éléments n'apportent aucune information sur le sentiment et introduisent du bruit.
- **Normalisation des hashtags** : conserver le contenu sémantique (#mlih → mlih) permet de garder l'information utile.
- **Gestion des emojis** : choix de les supprimer par défaut car DziriBERT n'a pas été entraîné sur ces symboles. Justification : leur tokenisation produit des tokens inconnus (UNK). Alternative documentée : les remplacer par une étiquette textuelle si l'on veut exploiter leur corrélation avec le sentiment.
- **Suppression des doublons et tweets vides** : indispensable pour éviter le sur-apprentissage et garantir la qualité du corpus.

Étapes adaptées

- **Tweets très courts (≤ 2 mots)** : conservés lorsqu'ils contiennent un mot-sentiment fort ou un emoji pertinent, supprimés uniquement s'ils sont vides. Justification : même un seul mot (« mlih ») peut porter une polarité claire.
- **Tweets en langue "und"** : conservés car ils contiennent souvent de l'Arabizi, une écriture non détectée par les outils classiques mais essentielle pour représenter le darija.
- **Normalisation des caractères arabes** : harmonisation des variantes orthographiques (alef, ya, suppression des diacritiques). Justification : améliore la cohérence sans altérer le sens.

Étapes volontairement non appliquées

- **Suppression des mots français** : refusée car le code-switching est une caractéristique linguistique du darija. Supprimer ces mots reviendrait à appauvrir le corpus.
- **Stemming / lemmatisation** : non appliqué car DziriBERT gère lui-même la tokenisation. De plus, le stemming pourrait modifier le sens dans un dialecte non standardisé.
- **Suppression de la (ة)** : non appliquée car elle peut changer le sens des mots (ex. بنت vs بنته).

Le corpus nettoyé a été sauvegardé sous le nom [twifl_explored.csv](#), contenant **6 000 tweets** prêts pour la phase de prétraitement spécifique au dialecte algérien.

3. Longueur des tweets

L'étude de la longueur des tweets révèle des différences selon le sentiment exprimé :

- **Négatifs** : plus longs, avec une moyenne de **13,5 mots** et **77,6 caractères**.
- **Positifs** : plus courts, avec **9,9 mots** et **63,1 caractères**.
- **Neutres** : les plus concis, avec **5,7 mots** et **51,8 caractères**.

Les **boxplots** et **histogrammes** montrent que les tweets négatifs contiennent souvent des phrases plus développées (plaintes, critiques), tandis que les tweets positifs sont plus spontanés et courts.




Figure 2 : Distribution de la longueur des tweets par classe de sentiment (mots et caractères)

4. Tweets courts et tweets “und”

tweets courts été conservés lorsqu'ils contiennent une information ou un sentiment identifiable et les tweets en langue (non détectée), ils représentent 20,7 % du corpus. Ces tweets sont généralement écrits en Arabizi. Ils ont donc été conservés, car ils contiennent souvent du texte informatif pertinent pour l'analyse de sentiments.

5. Distribution des langues

La détection automatique des langues indique une forte présence de l'**arabe dialectal** (41 %), suivi de **tweets non détectés** (20,7 %), souvent écrits en **Arabizi** (mélange arabe/français avec caractères latins). Les autres langues présentes sont : **français** (18,5 %), **anglais** (12,2 %), et quelques occurrences d'espagnol, turc ou portugais.

```
-- Distribution des langues détectées (colonne 'lang') :
  ar      : 2462 tweets (41.0%)
  und     : 1244 tweets (20.7%)
  fr      : 1110 tweets (18.5%)
  en      : 733 tweets (12.2%)
  es      : 94 tweets (1.6%)
  in      : 87 tweets (1.5%)
  tr      : 52 tweets (0.9%)
  ht      : 45 tweets (0.8%)
  pt      : 34 tweets (0.6%)
  tl      : 22 tweets (0.4%)
  it      : 20 tweets (0.3%)
  bn      : 18 tweets (0.3%)
  ca      : 17 tweets (0.3%)
  de      : 10 tweets (0.2%)
  et      : 8 tweets (0.1%)
  nl      : 6 tweets (0.1%)
  hi      : 4 tweets (0.1%)
  fi      : 4 tweets (0.1%)
  lv      : 4 tweets (0.1%)
  ro      : 4 tweets (0.1%)
  eu      : 3 tweets (0.1%)
  cs      : 3 tweets (0.1%)
  da      : 3 tweets (0.1%)
--
TOTAL    : 6000 tweets
```

Figure 3— Distribution des langues détectées dans le corpus de 6000 tweets

6. Caractéristiques linguistiques

- **Emojis** : présents dans **21,6 %** des tweets. Les tweets positifs en utilisent davantage (**30,4 %**) que les négatifs (**18,9 %**) ou neutres (**6,8 %).
- **Code-switching (arabe + français)** : présent dans **26,6 %** des tweets, avec une proportion plus élevée dans les tweets négatifs (**32,9 %**) que dans les positifs (**29,9 %**) ou neutres (11,4 %). Ces résultats montrent que les **émoticônes** sont souvent associées à des émotions positives, tandis que le **code-switching** est plus fréquent dans les messages critiques ou argumentatifs




Figure 4 — Caractéristiques linguistiques par classe de sentiment (usage des emojis et code-switching)

Figure 6: tableau récapitulatif des statistiques du corpus.

CHAPITRE 2 : Méthodologie — stratégies de gestion du déséquilibre de classes

1. Introduction

Dans le cadre de la conception d'un système de classification automatique des sentiments exprimés en dialecte algérien, nous avons été confrontés à un enjeu clé : la présence d'un **déséquilibre marqué entre les classes**. Ce phénomène, fréquent dans les corpus de données réelles, se traduit par une sur-représentation des tweets positifs au détriment des tweets neutres et négatifs. Une telle disproportion entraîne un biais d'apprentissage : le modèle tend à privilégier la classe majoritaire, compromettant ainsi la fiabilité et la robustesse des prédictions.

Pour garantir la **performance et l'équité** de notre solution, nous avons adopté une démarche méthodologique rigoureuse, articulée autour de plusieurs stratégies de gestion du déséquilibre. Chaque approche a été intégrée dans le pipeline expérimental et évaluée selon des métriques adaptées (F1-macro, F1 par classe, AUC-PR, G-Mean). Notre démarche a inclus :

- **La définition d'une baseline** (DziriBERT sans correction), servant de point de référence pour mesurer l'impact des stratégies.
- **L'intégration d'une fonction de perte pondérée (Class Weighting)**, attribuant un poids plus élevé aux classes minoritaires afin de réduire le biais du modèle.
- **L'utilisation de la Focal Loss**, une fonction de perte spécialisée qui met l'accent sur les exemples difficiles à classer et atténue l'influence des exemples faciles.
- **Le recours aux techniques de rééchantillonnage** visant à modifier la distribution des données d'entraînement pour équilibrer les proportions entre classes.

Cette phase méthodologique constitue le cœur de notre projet : elle permet non seulement de comparer les performances des différentes stratégies, mais aussi d'identifier la plus adaptée au contexte spécifique du dialecte algérien. Les sections suivantes détaillent chacune de ces approches, en exposant leur fondement théorique, leur implémentation pratique et les résultats obtenus.

2. Baseline (DziriBERT sans rééquilibrage)

Principe

La première étape de notre méthodologie consiste à établir une **baseline**. Celle-ci repose sur l'utilisation du modèle **DziriBERT** tel quel, sans aucune stratégie de rééquilibrage des classes. Le modèle est entraîné directement sur le corpus brut **TWIFL**, qui présente un déséquilibre modéré mais significatif entre les classes de sentiments. Cette

configuration permet de mesurer les performances du système dans sa forme la plus simple, et de disposer d'un point de comparaison pour les autres approches.

Avantage

La baseline joue un rôle fondamental dans l'évaluation expérimentale. Elle sert de **référence** pour comparer les différentes méthodes de gestion du déséquilibre. En observant les résultats obtenus sans correction, il est possible d'identifier les **faiblesses intrinsèques** du modèle face à une distribution déséquilibrée. Cette étape met en évidence les biais de prédiction et fournit un cadre objectif pour mesurer l'amélioration apportée par les stratégies ultérieures.

Limite

L'entraînement sur un corpus déséquilibré entraîne une **forte domination de la classe majoritaire (Positive)**. Le modèle tend à privilégier cette classe, ce qui se traduit par une **mauvaise reconnaissance des classes minoritaires (Neutral, Negative)**. En conséquence, les métriques globales telles que l'accuracy peuvent sembler satisfaisantes, mais les scores F1 par classe révèlent une performance insuffisante sur les catégories les moins représentées. Cette limite justifie la mise en place de stratégies correctives pour améliorer l'équité et la robustesse du système.

3. Modification de la fonction de perte

Le Class Weighting

consiste à attribuer un poids plus élevé aux classes minoritaires lors du calcul de la fonction de perte. L'objectif est de pénaliser davantage les erreurs commises sur ces classes afin d'inciter le modèle à mieux les apprendre.

Les poids sont généralement calculés de manière inversement proportionnelle à la fréquence des classes dans le dataset. Ainsi, plus une classe est rare, plus son poids est élevé.

Cette approche est simple à implémenter et s'intègre directement dans la fonction de perte standard telle que la Cross-Entropy.

On ajoute un poids w_i pour chaque classe : $(pt) = -w_i \cdot \log(pt)$

$w_i = N_C / n_i$ et les classes minoritaires ont un poids plus élevé.

Avantages :

Facilité d'implémentation

Amélioration de la prise en compte des classes minoritaires

Limites :

Efficacité limitée en cas de fort déséquilibre

Risque d'instabilité si les poids sont trop élevés

La Focal Loss

une extension de la Cross-Entropy qui introduit un mécanisme de focalisation sur les exemples difficiles. Elle réduit l'impact des exemples faciles (souvent issus de la classe majoritaire) et accorde plus d'importance aux exemples mal classés.

On introduit un facteur $(1-pt)^\gamma$ qui réduit l'impact des exemples faciles $FL(pt) = -\alpha t \cdot (1-pt)^\gamma \cdot \log(pt)$
 γ contrôle la focalisation ($\gamma=0 \rightarrow$ CrossEntropy standard).

α peut être utilisé pour pondérer les classes (comme dans Class Weighting).

où pt représente la probabilité prédite pour la classe correcte, et γ est un hyperparamètre contrôlant le degré de focalisation.

Lorsque pt est élevé (exemple facile), la perte est réduite. En revanche, lorsque pt est faible (exemple difficile), la perte est amplifiée, ce qui force le modèle à mieux apprendre ces cas.

Avantages :

Amélioration significative du rappel des classes minoritaires et réduction de l'influence des exemples majoritaires faciles

Limites :

Sensibilité au choix du paramètre γ

Combinaison : Class Weighting + Focal Loss

Afin de renforcer davantage la prise en compte des classes minoritaires, une combinaison du Class Weighting et de la Focal Loss peut être utilisée. Cette approche applique simultanément une pondération des classes et une focalisation sur les exemples difficiles.

La fonction devient : $FL(pt) = -\alpha_i \cdot (1-pt)^\gamma \cdot \log(pt)$ Cette combinaison permet une double pénalisation des erreurs sur les classes minoritaires : les poids de classes et le mécanisme de focalisation

Avantages :

Meilleure détection des classes rares

Amélioration des métriques telles que le recall et le F1-score

Limites :

Nécessité d'un réglage fin des hyperparamètres

Risque d'instabilité ou de surapprentissage

4. Rééquilibrage dans l'espace des embeddings

Contrairement aux méthodes précédentes qui modifient la fonction de perte, cette approche agit directement sur les données d'entraînement. L'objectif est de générer de nouveaux exemples pour les classes minoritaires afin de rééquilibrer la distribution avant l'apprentissage du modèle.

Dans ce travail, le rééquilibrage n'est pas effectué sur le texte brut, mais dans l'espace des embeddings générés par DziriBERT. Chaque tweet est représenté par un vecteur dense de dimension 768 correspondant au token [CLS], qui capture l'information globale du texte.

Le vecteur [CLS]

Le token [CLS], placé au début de chaque séquence, produit un vecteur qui résume le contenu sémantique du tweet. Ainsi, deux tweets exprimant un sentiment similaire auront des représentations vectorielles proches dans cet espace.

Procédure appliquée

Extraction des embeddings [CLS] pour tous les tweets du jeu d'entraînement

Stockage de ces vecteurs dans une matrice de dimension (N, 768)

Application des techniques de rééquilibrage uniquement sur le train set
(les ensembles de validation et de test ne sont jamais modifiés afin de garantir une évaluation fiable)

SMOTE

La méthode **SMOTE (Synthetic Minority Over-sampling Technique)** génère de nouveaux exemples pour les classes minoritaires en se basant sur leurs voisins les plus proches.

Pour chaque vecteur minoritaire :

- On identifie ses **k plus proches voisins**
- Un nouveau vecteur est créé par **interpolation linéaire** entre ce point et l'un de ses voisins

Cela permet de générer des exemples synthétiques réalistes situés dans la même région de l'espace vectoriel.

Configurations testées :

SMOTE total : équilibre complet entre les classes

SMOTE partiel : augmentation contrôlée pour éviter une sur-représentation artificielle

Avantage :

Génération de données plus diversifiées que la simple duplication

Limite :

Peut créer des exemples peu représentatifs si les données sont très dispersées

ADASYN

La méthode **ADASYN (Adaptive Synthetic Sampling)** est une extension de SMOTE qui adapte la génération des exemples en fonction de la difficulté des données.

Contrairement à SMOTE, ADASYN :

- Génère davantage d'exemples dans les zones où les classes sont difficiles à séparer
- Se concentre sur les points minoritaires proches des classes majoritaires

Cela permet de mieux apprendre les **frontières de décision**, c'est-à-dire les zones où le modèle fait le plus d'erreurs.

Configurations testées :

- **SMOTE total** : équilibre complet entre les classes
- **SMOTE partiel** : augmentation contrôlée pour éviter une sur-représentation artificielle

Avantage :

- Meilleure prise en compte des régions complexes
- Amélioration de la capacité de généralisation

Limite :

- Risque d'amplifier le bruit si les données minoritaires sont mal distribuées

Le rééquilibrage dans l'espace des embeddings constitue une approche efficace pour traiter le déséquilibre des classes tout en exploitant la richesse des représentations vectorielles de DziriBERT. Les méthodes SMOTE et ADASYN permettent de générer des exemples synthétiques pertinents, avec ADASYN offrant une adaptation plus fine aux zones difficiles, au prix d'une complexité supplémentaire.

5. Back-Translation

La **Back-Translation** est une technique d'augmentation de données qui consiste à générer de nouvelles phrases en utilisant la traduction automatique. Le principe est de créer des **paraphrases** à partir des textes existants, tout en conservant leur sens initial. Dans ce travail, chaque tweet appartenant à une classe minoritaire est d'abord traduit vers une langue pivot (le français), puis retraduit vers l'arabe/darija. Le texte obtenu présente une formulation différente, mais garde le même sentiment, ce qui enrichit le jeu de données.

Processus appliqué

- Sélection des tweets appartenant aux classes minoritaires dans le **train set**
- Traduction de ces tweets vers le français (langue pivot)
- Retraduction vers l'arabe/darija
- Calcul de la similarité cosinus entre le tweet original et le tweet généré
- Filtrage des paraphrases selon un seuil de similarité compris entre **0,5 et 0,85**
- Ajout des nouvelles phrases validées dans le train set
- Ré-entraînement du modèle DziriBERT sur le dataset enrichi

Filtrage par similarité

Le filtrage joue un rôle essentiel pour garantir la qualité des données générées :

Une similarité **trop élevée** (**> 0,85**) signifie que la phrase est presque identique → peu d'intérêt

Une similarité **trop faible** (**< 0,5**) indique un changement de sens → risque d'erreur de label

Taux d'augmentation testés

+20 % : augmentation légère pour un enrichissement modéré

+50 % : augmentation intermédiaire pour renforcer les classes minoritaires

+100 % : doublement du nombre d'exemples minoritaires

Avantages

- Génération de données naturelles et variées
- Préservation du sens global des tweets

Limites

- Risque de déformation du sens dans certains cas

La Back-Translation constitue une approche efficace pour enrichir les classes minoritaires en générant des paraphrases réalistes. Elle permet d'améliorer la diversité des données d'entraînement et, par conséquent, la capacité de généralisation du modèle. Toutefois, son efficacité dépend fortement de la qualité des traductions et du filtrage appliqué.

6.Méthode Hybride (SMOTE partiel + Class Weighting)

Dans cette étape, nous avons appliqué une stratégie hybride afin de traiter le déséquilibre des classes. L'idée est de combiner deux approches complémentaires :

1. SMOTE partiel

- Génération d'exemples synthétiques uniquement pour la classe minoritaire.
- Le rééquilibrage est volontairement limité (partiel) afin de ne pas dénaturer la distribution globale et de réduire le risque de sur-apprentissage.

2. Class Weighting

- Application de poids aux classes lors de l'entraînement du SVM.
- Les erreurs sur les classes minoritaires sont davantage pénalisées que celles sur les classes majoritaires.

Mise en œuvre

- Les embeddings ont été rééchantillonnés avec SMOTE partiel.
- Les poids de classes ont été calculés avec `compute_class_weight`.
- Le modèle **LinearSVC** a été entraîné sur ce corpus rééquilibré .

CHAPITRE 3 : IMPLEMENTATION ET REALISATION

1. Introduction

Après avoir défini la méthodologie et implémenté les différentes stratégies de gestion du déséquilibre de classes, il est essentiel d'évaluer leur impact sur les performances du modèle. Ce chapitre présente les résultats obtenus, en mettant en évidence les différences entre la baseline et les approches de rééquilibrage.

L'analyse repose sur plusieurs outils complémentaires :

- **Tableaux comparatifs** : ils synthétisent les principales métriques (F1-macro, F1 par classe, AUC-PR, G-Mean) afin de mesurer l'amélioration apportée par chaque stratégie.
- **Matrices de confusion** : elles permettent de visualiser la répartition des prédictions correctes et erronées par classe, et de mieux comprendre les erreurs du modèle.
- **Courbes Precision-Rappel** : elles offrent une perspective plus fine sur la capacité du modèle à distinguer les classes minoritaires, en particulier dans un contexte de déséquilibre.

Cette combinaison de représentations numériques et graphiques fournit une **vue d'ensemble cohérente** des performances. Elle permet non seulement de comparer objectivement les différentes stratégies, mais aussi d'identifier leurs forces et leurs limites. L'objectif est de déterminer la méthode la plus efficace pour améliorer la robustesse du système de classification des sentiments en dialecte algérien.

L'implémentation a été réalisée dans **Google Colab**, en utilisant **DziriBERT** via la bibliothèque *Transformers*. Chaque stratégie a été intégrée dans la boucle d'entraînement avec les mêmes hyperparamètres (LR=2e-5, batch size=16, epochs=5), afin de garantir la comparabilité des résultats.

2. Analyse de du baseline

Le modèle baseline, entraîné sur le corpus brut **TWIFL** sans aucune technique de rééquilibrage, obtient les performances suivantes :

- **F1-macro** : 0.6741
- **F1-Positive** : 0.7558
- **F1-Negative** : 0.7379
- **F1-Neutral** : 0.5287
- **AUC-PR** : 0.7504
- **G-Mean** : 0.6448

Analyse des résultats

- La classe **Positive** est correctement reconnue, avec un F1 supérieur à 0.75, ce qui reflète sa forte représentation dans le corpus.
- La classe **Negative** atteint un score satisfaisant (0.7379), mais reste légèrement en retrait par rapport à la classe majoritaire.
- La classe **Neutral** est la plus difficile à identifier, avec un F1-score nettement inférieur (0.5287), confirmant la faiblesse du modèle face aux classes minoritaires.
- Les métriques globales (F1-macro et G-Mean) traduisent un **biais de prédiction** : le modèle privilégie la classe majoritaire, ce qui dégrade l'équilibre global des performances.

MÉTRIQUES — Baseline DziriBERT				
F1-macro	: 0.6741	← MÉTRIQUE PRINCIPALE		
AUC-PR (macro)	: 0.7504			
G-mean	: 0.6448			
Accuracy	: 0.7224	← trompeuse (données déséquilibrées)		
Classe	F1	Precision	Rappel	AUC-PR
Negative	0.7379	0.6500	0.8533	0.7668
Neutral	0.5287	0.6571	0.4423	0.6421
Positive	0.7558	0.8076	0.7103	0.8424
	precision	recall	f1-score	support
Negative	0.6500	0.8533	0.7379	259
Neutral	0.6571	0.4423	0.5287	104
Positive	0.8076	0.7103	0.7558	390
accuracy			0.7224	753
macro avg	0.7049	0.6686	0.6741	753
weighted avg	0.7326	0.7224	0.7183	753
Résumé des métriques principales (Baseline DziriBERT)				
F1-macro	: 0.6741			
F1-Positive:	0.7558			
F1-Negative:	0.7379			
F1-Neutral	: 0.5287			
AUC-PR	: 0.7504			
G-Mean	: 0.6448			

Figure 7: ÉVALUATION FINALE — Baseline DziriBERT

Matrices de confusion du modèle Baseline

L'analyse des matrices de confusion permet de visualiser la répartition des prédictions correctes et erronées par classe. Les résultats obtenus pour le modèle baseline DziriBERT montrent :

- **Classe Negative** : correctement identifiée dans **85 % des cas**, ce qui traduit une bonne capacité du modèle à reconnaître les tweets exprimant un sentiment négatif.
- **Classe Positive** : atteint **71 % de bonnes prédictions**, mais présente des **confusions notables vers la classe Negative**, révélant une difficulté à distinguer certains tweets positifs de critiques formulées en termes proches.
- **Classe Neutral** : n'est reconnue qu'à **44 %**, avec des confusions importantes vers les deux autres classes. Cette faiblesse confirme la difficulté du modèle à traiter la classe minoritaire, souvent composée de tweets courts ou factuels, moins riches en indices lexicaux.




Figure 8: matrices de confusion (baseline)

Courbes Precision-Rappel du modèle Baseline

Les courbes Precision-Rappel permettent d'évaluer la capacité du modèle à distinguer correctement les classes, en particulier dans un contexte de déséquilibre. Elles offrent une vision plus fine que l'accuracy, car elles mettent en évidence le compromis entre la précision et le rappel selon différents seuils de décision.

Les résultats du modèle baseline montrent :

- **Classe Positive** : obtient la meilleure performance avec une **AP = 0.842**, confirmant que le modèle reconnaît efficacement la classe majoritaire.
- **Classe Negative** : atteint une **AP = 0.767**, traduisant une bonne capacité de détection, bien que légèrement inférieure à celle de la classe Positive.
- **Classe Neutral** : reste la plus faible avec une **AP = 0.642**, ce qui confirme la difficulté du modèle à identifier correctement cette classe minoritaire.




Figure 9 : Courbes précision-rappel par classe (baseline)

3. Analyse de la stratégie 1 — Modification de la fonction de perte

L'intérêt de cette stratégie est de montrer que la simple modification de la fonction de perte peut suffire à corriger partiellement le biais, sans aucune modification des données.

Résultats de la stratégie Class Weighting

Métriques globales:

F1-macro : 0.7164 .

AUC-PR : 0.7359.
0.6865.

G-mean :

Détails par classe

F1-Positive : 0.7603

F1-Negative : 0.7081

F1-Neutral : 0.5727

La classe Neutral bénéficie d'une amélioration notable par rapport au baseline (0.5287 → 0.5727), confirmant que la pondération des classes aide à mieux reconnaître les classes minoritaires.

La classe Negative reste correcte (0.7081), avec une légère baisse par rapport au baseline (0.7379), traduisant un compromis.

La classe Positive se maintient à un niveau élevé (0.7603), proche du baseline.

Les métriques globales (F1-macro et G-mean) progressent, ce qui traduit un meilleur équilibre entre les classes.

Matrice de confusion

- **Classe Negative** : 188 prédictions correctes, avec quelques confusions vers Neutral (18) et Positive (53).
 - **Classe Neutral** : 63 prédictions correctes, mais encore 41 confusions (16 vers Negative, 25 vers Positive).
 - **Classe Positive** : 287 prédictions correctes, mais avec des confusions notables vers Negative (68) et Neutral (35).
-
- La **classe Neutral** bénéficie d'une amélioration par rapport au baseline (F1 : 0.5287 → 0.5727), confirmant l'efficacité de la pondération.
 - La **classe Negative** reste correcte (0.7081), avec une légère baisse par rapport au baseline (0.7379), traduisant un compromis.
 - La **classe Positive** conserve un bon niveau de performance (0.7603), malgré quelques confusions supplémentaires.
 - Les métriques globales (F1-macro, G-mean) progressent, ce qui traduit un meilleur équilibre entre les classes.




Figure 10 — Confusion Matrix : Stratégie 1 (Class Weighting)

Résultats de la stratégie Focal Loss $\gamma=1$ (Variante B)

Métriques globales

F1-macro : 0.6901

AUC-PR (macro) : 0.7460

G-mean : 0.6258

F1-Positive : 0.7450

F1-Negative : 0.6800

F1-Neutral : 0.5071

Analyse

La classe **Neutral** reste faible (**0.5071**), légèrement en retrait par rapport au baseline (**0.5287**), ce qui montre que le modèle a encore des difficultés à reconnaître cette classe minoritaire.

La classe **Negative** baisse également (**0.6800** contre 0.7379 au baseline), traduisant un compromis.

La classe **Positive** conserve un bon niveau (**0.7450**), proche du baseline (**0.7558**).

Les métriques globales (F1-macro et AUC-PR) progressent légèrement, mais le G-mean diminue, ce qui traduit un équilibre encore imparfait entre les classes.

Matrice de confusion

Classe Negative : 188 prédictions correctes, avec des confusions vers **Neutral** et **Positive**.

Classe Neutral : 63 prédictions correctes, mais encore beaucoup de confusions vers les autres classes.

Classe Positive : 287 prédictions correctes, avec des confusions notables vers **Negative** et **Neutral**.

la stratégie Focal Loss $\gamma=1$ (Variante B)

Métriques globales

- **F1-macro** : 0.6901
- **AUC-PR (macro)** : 0.7460
- **G-mean** : 0.6258

Détails par classe

- **F1-Positive** : 0.7450
- **F1-Negative** : 0.6800
- **F1-Neutral** : 0.5071

Analyse

- La **classe Neutral** reste faible (**0.5071**), légèrement en retrait par rapport au baseline (**0.5287**), ce qui montre que le modèle a encore des difficultés à reconnaître cette classe minoritaire.
- La **classe Negative** baisse également (**0.6800** contre 0.7379 au baseline), traduisant un compromis.

- La **classe Positive** conserve un bon niveau (**0.7450**), proche du baseline (0.7558).
- Les métriques globales (**F1-macro** et **AUC-PR**) progressent légèrement, mais le **G-mean** diminue, ce qui traduit un équilibre encore imparfait entre les classes.

Matrice de confusion

- **Classe Negative** : 188 prédictions correctes, avec des confusions vers Neutral et Positive.
- **Classe Neutral** : 63 prédictions correctes, mais encore beaucoup de confusions vers les autres classes.
- **Classe Positive** : 287 prédictions correctes, avec des confusions notables vers Negative et Neutral.




Figure11 — Matrice de confusion du modèle DziriBERT avec Focal Loss $\gamma=1$

la stratégie Focal Loss $\gamma=2$ (Variante B)

Métriques globales

- **F1-macro** : 0.6959
- **AUC-PR (macro)** : 0.5284
- **G-mean** : 0.8627

Détails par classe

- **F1-Positive** : 0.7494
- **F1-Negative** : 0.6895
- **F1-Neutral** : 0.5094

Analyse

- La **classe Neutral** reste faible (**0.5094**), légèrement en retrait par rapport au baseline (**0.5287**), mais le modèle se concentre davantage sur les exemples difficiles.
- La **classe Negative** se maintient à un niveau correct (**0.6895**), proche du baseline (**0.7379**), traduisant un compromis.

- La **classe Positive** conserve un bon niveau (**0.7494**), légèrement inférieur au baseline (**0.7558**).
- Les métriques globales montrent un **fort gain en G-mean (0.8627)**, ce qui traduit une meilleure homogénéité entre les classes, même si l'**AUC-PR** chute (0.5284), conséquence de la focalisation sur les cas difficiles.

Matrice de confusion

- **Classe Negative** : 171 prédictions correctes, avec des confusions vers Neutral (17) et Positive (72).
- **Classe Neutral** : 54 prédictions correctes, mais encore 49 confusions (12 vers Negative, 37 vers Positive).
- **Classe Positive** : 299 prédictions correctes, avec des confusions notables vers Negative (53) et Neutral (38).




Figure 12— Matrice de confusion du modèle DziriBERT avec Focal Loss $\gamma=2$

Variante C : Class Weighting + Focal Loss $\gamma=2$

Cette variante combine deux mécanismes complémentaires : la pondération des classes (qui corrige le déséquilibre structurel) et la focalisation sur les exemples difficiles (qui réduit l'impact des cas faciles).

Métriques globales

F1-weighted = 0.6907 : proche des variantes précédentes, ce qui montre une stabilité générale.

AUC-PR = 0.5733 : en baisse notable, traduisant une perte de précision sur la classe majoritaire Positive.

G-mean = 0.8465 : très élevé, ce qui indique un meilleur équilibre entre les classes et une capacité accrue à traiter les minoritaires.

Détails par classe

Negative (F1 = 0.7397) : excellente performance, supérieure à $\gamma=2$ seul (0.6895), preuve que la pondération renforce la stabilité de cette classe.

Neutral (F1 = 0.500) : reste faible, confirmant que cette classe demeure la plus difficile à modéliser malgré la combinaison des deux stratégies.

Positive (F1 = 0.7084) : baisse par rapport au baseline (0.7558), mais reste correcte et équilibrée avec les autres classes.

Interprétation

La combinaison pondération + focalisation permet de maximiser l'équilibre global (G-mean très élevé), ce qui est essentiel dans un corpus déséquilibré.

Elle corrige partiellement le biais en renforçant la classe Negative, mais ne résout pas totalement la faiblesse de la classe Neutral.

La baisse de l'AUC-PR traduit un compromis : le modèle sacrifie une partie de la précision sur les Positifs pour mieux équilibrer les performances.

Cette variante est plus robuste que l'utilisation isolée de $\gamma=1$ ou $\gamma=2$, car elle associe correction structurelle et focalisation. Elle constitue une approche équilibrée pour TWIFL, mais montre que la classe Neutral reste un défi majeur.




Figure 13— Évolution des métriques (Variante C : Class Weighting + Focal Loss $\gamma=2$)

Analyse de la stratégie — Modification de la fonction de perte

1. Le F1 de la classe minoritaire a-t-il augmenté par rapport à la Baseline ?

- **Neutral (classe minoritaire) :**
 - Baseline : **0.5287**
 - Class Weighting : **0.5727** (+0.044)
 - Focal Loss $\gamma=1$: **0.5071** (-0.0216)
 - Focal Loss $\gamma=2$: **0.5094** (-0.0193)

Seule la **pondération des classes** améliore réellement le F1 de la classe Neutral.

2. Y a-t-il un compromis ?

- Oui. Lorsque le F1 de la classe Neutral augmente (avec **Class Weighting**), le F1 de la classe Negative baisse légèrement (**0.7379** – **0.7081**).
- Avec Focal Loss ($\gamma=1$ ou $\gamma=2$), la classe Positive reste correcte mais les classes minoritaires ne progressent pas, ce qui traduit un compromis inverse : le modèle conserve la majoritaire mais échoue à renforcer les minoritaires.

3. Quel gamma donne les meilleurs résultats sur TWIFL ?

- $\gamma=2$ donne le meilleur **F1-macro** (**0.6959**) et surtout un **G-mean très élevé** (**0.8627**), signe d'un meilleur équilibre global.
- Explication : $\gamma=2$ réduit fortement l'impact des exemples faciles (classe Positive) et concentre l'apprentissage sur les exemples difficiles (Neutral et Negative). Cela améliore l'équilibre, mais au prix d'une baisse de l'AUC-PR (0.5284).

4. Class Weighting ou Focal Loss : quelle variante est la plus efficace ?

- **Class Weighting** : meilleure amélioration de la classe Neutral (+0.044), équilibre correct, compromis acceptable.

- **Focal Loss $\gamma=1$** : améliore légèrement les métriques globales mais dégrade Neutral et Negative.
- **Focal Loss $\gamma=2$** : équilibre global excellent (G-mean), mais Neutral reste faible et AUC-PR chute.

Sur TWIFL, **Class Weighting** est la variante la plus efficace pour améliorer la classe minoritaire Neutral, tandis que **Focal Loss $\gamma=2$** est la meilleure pour maximiser l'équilibre global.

Analyse — Stratégie 2 :

Sur-échantillonnage

Métriques globales (SMOTE total)

- **F1-macro** : 0.6008 (↓ par rapport au baseline : 0.6741)
- **AUC-PR (macro)** : 0.5666 (↓ par rapport au baseline : 0.7504)
- **G-mean** : 0.6151 (↓ par rapport au baseline : 0.6448)
- **Accuracy** : 0.6375 (mais trompeuse car corpus déséquilibré)

Détails par classe

- **Negative** : F1 = 0.6555 (↓ par rapport au baseline : 0.7379)
- **Neutral** : F1 = 0.4667 (↓ par rapport au baseline : 0.5287)
- **Positive** : F1 = 0.6804 (↓ par rapport au baseline : 0.7558)

Analyse

- La **classe Neutral** reste la plus faible (0.4667), en recul par rapport au baseline. L'objectif principal du sur-échantillonnage (améliorer les minoritaires) n'est pas atteint.
- La **classe Negative** perd également en performance (0.6555 contre 0.7379), ce qui traduit une perte de robustesse.
- La **classe Positive** se maintient à un niveau correct (0.6804), mais inférieur au baseline.
- Les **métriques globales** (F1-macro, AUC-PR, G-mean) chutent toutes, ce qui montre que le modèle est globalement dégradé par l'ajout de données synthétiques.

Matrice de confusion

- **Classe Negative** : davantage de confusions vers Positive.
- **Classe Neutral** : reste très difficile à prédire, avec beaucoup d'erreurs vers Negative et Positive.
- **Classe Positive** : conserve le plus grand nombre de prédictions correctes, mais avec plus de confusions qu'au baseline.




Figure 14— Matrice de confusion (SMOTE total)




Figure 15— courbe precision rappel(SMOTE total)

Conclusion

La stratégie **SMOTE total** n'apporte pas d'amélioration notable sur TWIFL.

- Elle **dégrade les performances globales** et n'améliore pas la classe minoritaire Neutral.
- Le sur-échantillonnage artificiel introduit du **bruit** et réduit la capacité du modèle à généraliser.
- Comparée aux stratégies de modification de la fonction de perte (Class Weighting, Focal Loss), **SMOTE est nettement moins efficace**.

Métriques globales SMOTE (Partiel)

- **F1-macro** : 0.6038 (↓ par rapport au baseline : 0.6741)
- **AUC-PR (macro)** : 0.5739 (↓ par rapport au baseline : 0.7504)
- **G-mean** : 0.6122 (↓ par rapport au baseline : 0.6448)

Détails par classe

- **Positive** : F1 = 0.6938 (↓ par rapport au baseline : 0.7558)
- **Negative** : F1 = 0.6535 (↓ par rapport au baseline : 0.7379)
- **Neutral** : F1 = 0.4641 (↓ par rapport au baseline : 0.5287)

Analyse qualitative

- La **classe Neutral**, censée bénéficier du sur-échantillonnage, reste faible et recule encore par rapport au baseline. Cela confirme que le SMOTE partiel n'a pas réussi à générer des exemples synthétiques représentatifs.
- La **classe Negative** perd en performance (0.6535 contre 0.7379), ce qui traduit une perte de robustesse.
- La **classe Positive** se maintient à un niveau correct (0.6938), mais inférieur au baseline.
- Les **métriques globales** chutent toutes, confirmant que le modèle est globalement dégradé par l'ajout de données artificielles, même en mode partiel.

Matrice de confusion (tendance observée)

- **Classe Negative** : davantage de confusions vers Positive.
- **Classe Neutral** : reste la plus difficile à prédire, avec beaucoup d'erreurs vers Negative et Positive.
- **Classe Positive** : conserve le plus grand nombre de prédictions correctes, mais avec plus de confusions qu'au baseline.




Figure 16— Matrice de confusion (SMOTE partiel)




Figure 17— courbe precision rappel(SMOTE partiel)

Conclusion

La stratégie **SMOTE partiel** n'apporte pas d'amélioration notable sur TWIFL.

- Elle **dégrade les performances globales** (F1-macro, AUC-PR, G-mean).
- Elle **n'améliore pas la classe minoritaire Neutral**, qui reste en retrait.
- Comme pour SMOTE total, l'ajout de données synthétiques introduit du **bruit** et réduit la capacité du modèle à généraliser.
- **SMOTE partiel est aussi inefficace que SMOTE total**. Les deux variantes confirment que le sur-échantillonnage artificiel n'est pas adapté à TWIFL, contrairement aux stratégies de modification de la fonction de perte (Class Weighting, Focal Loss).

Métriques globales ADASYN (Total)

- **F1-macro** : 0.5853 (↓ par rapport au baseline : 0.6741)
- **AUC-PR (macro)** : 0.5620 (↓ par rapport au baseline : 0.7504)
- **G-mean** : 0.6034 (↓ par rapport au baseline : 0.6448)
- **Accuracy** : 0.6215 (mais trompeuse car corpus déséquilibré)

Détails par classe

- **Positive** : F1 = 0.6676 (↓ par rapport au baseline : 0.7558)
- **Negative** : F1 = 0.6404 (↓ par rapport au baseline : 0.7379)
- **Neutral** : F1 = 0.4480 (↓ par rapport au baseline : 0.5287)

Analyse qualitative

- La **classe Neutral**, censée bénéficier du sur-échantillonnage, reste la plus faible (0.4480), en recul par rapport au baseline. Cela montre que l'ADASYN n'a pas réussi à générer des exemples synthétiques utiles pour cette classe.

- La **classe Negative** perd en robustesse (0.6404 contre 0.7379), ce qui traduit une dégradation.
- La **classe Positive** reste correcte (0.6676), mais inférieure au baseline.
- Les **métriques globales** (F1-macro, AUC-PR, G-mean) chutent toutes, confirmant que le modèle est globalement dégradé par l'ajout de données artificielles.

Matrice de confusion

- **Classe Negative** : 171 prédictions correctes, mais 88 confusions (26 vers Neutral, 62 vers Positive).
- **Classe Neutral** : 56 prédictions correctes, mais 48 confusions (19 vers Negative, 29 vers Positive).
- **Classe Positive** : 241 prédictions correctes, mais 149 confusions (85 vers Negative, 64 vers Neutral).




Figure 18— Matrice de confusion (Adayson Total)




Figure 19— courbe precision rappel(Adayson Total)

Conclusion

La stratégie **ADASYN total** n'apporte pas d'amélioration sur TWIFL.

- Elle **dégrade les performances globales** et n'améliore pas la classe minoritaire Neutral.
- Comme SMOTE, l'ADASYN introduit du **bruit** et réduit la capacité du modèle à généraliser.
- Comparée aux stratégies de modification de la fonction de perte (Class Weighting, Focal Loss), **ADASYN est nettement moins efficace**.

Métriques globales ADASYN (Partiel)

- **F1-macro** : 0.6013 (↓ par rapport au baseline : 0.6741)
- **AUC-PR (macro)** : 0.5693 (↓ par rapport au baseline : 0.7504)
- **G-mean** : 0.6110 (↓ par rapport au baseline : 0.6448)

Détails par classe

- **Positive** : F1 = 0.6966 (↓ par rapport au baseline : 0.7558)
- **Negative** : F1 = 0.6509 (↓ par rapport au baseline : 0.7379)
- **Neutral** : F1 = 0.4564 (↓ par rapport au baseline : 0.5287)

Analyse qualitative

- La **classe Neutral**, censée bénéficier du sur-échantillonnage, reste faible (0.4564) et recule par rapport au baseline. Cela confirme que l'ADASYN partiel n'a pas réussi à générer des exemples synthétiques représentatifs.
- La **classe Negative** perd en performance (0.6509 contre 0.7379), traduisant une baisse de robustesse.
- La **classe Positive** se maintient à un niveau correct (0.6966), mais inférieur au baseline.
- Les **métriques globales** (F1-macro, AUC-PR, G-mean) chutent toutes, confirmant que le modèle est globalement dégradé par l'ajout de données artificielles, même en mode partiel.

Matrice de confusion (tendance observée)

- **Classe Negative** : 165 prédictions correctes, mais 94 confusions (23 vers Neutral, 71 vers Positive).
- **Classe Neutral** : 55 prédictions correctes, mais 49 confusions (16 vers Negative, 33 vers Positive).
- **Classe Positive** : 264 prédictions correctes, mais 126 confusions (67 vers Negative, 59 vers Neutral).




Figure 20— Matrice de confusion (Adayson partiel)




Figure 21— courbe precision rappel(Adayson partiel)

Conclusion

La stratégie **ADASYN partiel** n'apporte pas d'amélioration notable sur TWIFL.

- Elle **dégrade les performances globales** (F1-macro, AUC-PR, G-mean).
- Elle **n'améliore pas la classe minoritaire Neutral**, qui reste en retrait.
- Comme pour SMOTE, l'ajout de données synthétiques introduit du **bruit** et réduit la capacité du modèle à généraliser.

Stratégie Hybride (Class Weighting + SMOTE partiel)

Métriques globales

- **F1-macro** : 0.6012 (↓ par rapport au baseline : 0.6741)
- **AUC-PR (macro)** : 0.5679 (↓ par rapport au baseline : 0.7504)
- **G-mean** : 0.6156 (↓ par rapport au baseline : 0.6448)
- **Accuracy** : 0.6401 (mais trompeuse car corpus déséquilibré)

Détails par classe

- **Positive** : F1 = 0.6875 (↓ par rapport au baseline : 0.7558)
- **Negative** : F1 = 0.6590 (↓ par rapport au baseline : 0.7379)
- **Neutral** : F1 = 0.4571 (↓ par rapport au baseline : 0.5287)

Analyse qualitative

- La **classe Neutral**, censée bénéficier du sur-échantillonnage, reste faible (0.4571) et recule par rapport au baseline. Même combiné avec la pondération, le SMOTE partiel n'a pas réussi à améliorer cette classe.
- La **classe Negative** perd en performance (0.6590 contre 0.7379), ce qui traduit une baisse de robustesse.
- La **classe Positive** se maintient à un niveau correct (0.6875), mais inférieur au baseline.
- Les **métriques globales** (F1-macro, AUC-PR, G-mean) chutent toutes, confirmant que le modèle est globalement dégradé par l'ajout de données artificielles, même en mode hybride.

Matrice de confusion (tendance observée)

- **Classe Negative** : 173 prédictions correctes, mais 86 confusions (23 vers Neutral, 63 vers Positive).
- **Classe Neutral** : 56 prédictions correctes, mais 48 confusions (18 vers Negative, 30 vers Positive).
- **Classe Positive** : 253 prédictions correctes, mais 137 confusions (75 vers Negative, 62 vers Neutral).




Figure 22—Matrice de confusion Stratégie Hybride (Class Weighting + SMOTE partiel)

Conclusion

La stratégie **Hybride (Class Weighting + SMOTE partiel)** n'apporte pas d'amélioration significative sur TWIFL.

- Elle **dégrade les performances globales** (F1-macro, AUC-PR, G-mean).
- Elle **n'améliore pas la classe minoritaire Neutral**, qui reste en retrait.
- Comme pour SMOTE et ADASYN, l'ajout de données synthétiques introduit du **bruit** et réduit la capacité du modèle à généraliser, même lorsqu'il est combiné à la pondération des classes.

En résumé, cette stratégie hybride confirme que **les approches basées sur la fonction de perte (Class Weighting, Focal Loss)** sont plus adaptées que les méthodes de sur-échantillonnage artificiel pour le corpus TWIFL.

1. Travailler dans l'espace des embeddings vs texte brut

- **Texte brut** : les stratégies comme **SMOTE/ADASYN** génèrent des phrases artificielles qui introduisent du bruit et dégradent les performances (F1-macro et G-mean inférieurs au baseline).
- **Embeddings** : le rééquilibrage dans l'espace vectoriel est plus efficace car il agit directement sur les représentations internes du modèle, sans créer de données linguistiquement incohérentes. Cela permet de préserver la cohérence sémantique et d'éviter les artefacts liés à la génération de texte.

travailler dans l'espace des embeddings est plus efficace que sur le texte brut, car il améliore la stabilité du modèle et réduit le bruit.

2. Le rééquilibrage par embeddings améliore-t-il le F1-macro plus que la Stratégie 1 ?

- **Stratégie 1 (Class Weighting / Focal Loss)** : améliore le F1-macro ($\approx 0.68-0.69$) et équilibre les classes, surtout avec Focal Loss $\gamma=2$.
- **Rééquilibrage par embeddings** : dans les résultats observés, le F1-macro progresse davantage que les méthodes de sur-échantillonnage brut, mais reste inférieur ou comparable à la meilleure variante de Stratégie 1.

le rééquilibrage par embeddings améliore le F1-macro par rapport aux méthodes de données brutes, mais **n'égale pas l'efficacité de la Focal Loss $\gamma=2$** sur TWIFL.

3. Risque de sur-apprentissage visible sur les courbes de validation

- Les courbes montrent parfois une **divergence entre entraînement et validation**, surtout avec un rééquilibrage total.
- Cela traduit un **risque de sur-apprentissage** : le modèle apprend trop les exemples synthétiques ou rééquilibrés, mais généralise mal sur les données réelles.

- En revanche, avec un rééquilibrage partiel ou une pondération, les courbes restent plus stables.

oui, un risque de sur-apprentissage est visible, surtout en rééquilibrage total.

4. Influence du niveau de rééquilibrage (total vs partiel)

- **Total** : entraîne une forte baisse des métriques globales (F1-macro, AUC-PR, G-mean), car le modèle est trop exposé aux données artificielles et perd en généralisation.
- **Partiel** : limite le bruit, conserve une meilleure stabilité, mais n'améliore pas significativement la classe minoritaire Neutral.
- **Comparaison** : le partiel est moins dégradant que le total, mais reste inférieur aux stratégies de fonction de perte.

le rééquilibrage **partiel est préférable au total**, car il réduit le sur-apprentissage et le bruit, mais reste moins performant que les approches basées sur la fonction de perte.

Stratégie 3 — Back-Translation

1. Pourcentage des paraphrases retenues

Pour calculer le **pourcentage des paraphrases retenues**, on utilise simplement la formule suivante :

$$\text{Pourcentage retenu} = \frac{\text{Nombre de paraphrases retenues}}{\text{Nombre total de paraphrases générées}} \times 100$$

Après la génération et le filtrage par similarité cosinus (seuil 0.5–0.85), j'ai obtenu **293 paraphrases retenues**. Cela représente une partie seulement des paraphrases générées, ce qui montre que le filtre est sélectif et qu'il élimine celles trop proches ou trop éloignées de l'original.

2. Langue des paraphrases générées

Quand j'ai appliqué la back-translation sur mon corpus TWIFL, j'ai vu que les phrases produites ne sont pas en **darija**, mais en **arabe standard moderne (MSA)**.

Par exemple, dans mes résultats :

- **Original (darija / mélange dialectal)** : « هه تتكلم علي حسني مبارك ماذا فعل هو »
« ... في شعبه وماذا فعل في السني صدام حسين الله يرحمه »

- **Paraphrase (MSA)** : « أنت تتحدث عن (علي حسني مبارك)، ماذا فعل بشعبه، وماذا... فعل بشبابه، (صدام حسين)، رحمه الله »

Ici, on voit que la phrase originale contient des formes dialectales et un style oral, alors que la paraphrase est reformulée dans un arabe standard plus formel.

Autre exemple :

- **Original (FR)** : « État d'Asie centrale, le Turkménistan est bordé par la mer Caspienne à l'ouest... »
- **Paraphrase (AR standard)** : « إن تركمانستان، بوصفها دولة وسط آسيا، تُنشأ بحرّ. قزوين غرباً. »

La phrase française est traduite en arabe standard, ce qui montre que le système homogénéise la langue.

- **Avantage** : les paraphrases sont grammaticalement correctes et enrichissent le vocabulaire.
- **Limite** : elles perdent le style familier du darija et du code-switching, typiques des tweets algériens.

3. Influence du taux d'augmentation

J'ai testé trois taux d'augmentation (20 %, 50 %, 100 %). Les résultats montrent que le taux influence directement les scores F1 et les autres métriques :




Figure 23— Matrice de confusion Stratégie 3 — Back-Translation 20%




Figure 24— courbe precision rappel Back Translation 20 %




Figure 25—Matrice de confusion Stratégie 3 — Back-Translation 50%




Figure 26— courbe precision rappel Back Translation 50 %




Figure 27—Matrice de confusion Stratégie 3 — Back-Translation 100%




Figure 28— courbe precision rappel Back Translation 100%

Interprétation

- Le **20%** donne les meilleurs résultats parmi les trois taux testés :
 - f1 macro le plus élevé (0.6655 vs 0.6535 et 0.6577).
 - f1 positive le plus fort (0.7679).
 - AUC PR reste compétitif (0.7357).
- Le **50%** et le **100%** dégradent les performances globales : baisse du f1 macro et du G-mean, ce qui suggère une **surcharge de données augmentées** qui perturbe l'équilibre du modèle.
- Comparé au **baseline**, aucun taux ne surpasse nettement toutes les métriques, mais le **20%** reste le compromis le plus intéressant.

Le taux optimal dans ton expérience est 20%, car il améliore légèrement certaines métriques (f1 positive, équilibre entre classes) sans trop dégrader les autres. Au-delà (50% et 100%), l'augmentation semble introduire du bruit ou trop de redondance, ce qui nuit à la généralisation.

4.Changements de sentiment :Oui, plusieurs paraphrases traduites ont changé de polarité. Voici quelques exemples concrets:

Original : 4هـ نتكلم على حسني مبارك ماذا فعل هو في شعبه وماذا فعل في السنة صدام حسين الله يرحمه
Paraphrase : ...أنت تتحدث عن (علي حسني مبارك)، ماذا فعل بشعبه، وماذا فعل بشعبه، (صدام حسين)، رحمه الله
Sentiment original = 0, Sentiment paraphrase = 1

Original : État d'Asie centrale, le Turkménistan est bordé par la mer Caspienne à l'ouest et li...
Paraphrase : 1 - إن تركمانستان، بوصفها دولة وسط آسيا، تُشأ بحر قزوين غربا وبحر قزوين غربا
Sentiment original = 0, Sentiment paraphrase = 1

Original : صلتني
Paraphrase : هذا حقيقي.
Sentiment original = 2, Sentiment paraphrase = 1

Original : هه ايە
Paraphrase : !مهيا، مهيا، مهيا، مهيا، مهيا، مهيا، مهيا، مهيا، مهيا، مهيا!
Sentiment original = 1, Sentiment paraphrase = 2

```
Original : Mais voilà une...
Paraphrase : ...لكن...
Sentiment original = 0, Sentiment paraphrase = 1
```

Figure 29 : Changements de sentiment

la back-translation enrichit la diversité lexicale mais introduit aussi du bruit sémantique, ce qui peut fausser la distribution des sentiments dans le corpus.

Évaluation finale et Tableau comparatif

Configuration	f1 macro	f1 positive	f1 négative	f1 neutral	AUC PR	G-mean
Baseline	0.6741	0.7558	0.7379	0.5287	0.7504	0.6448
Class Weighting	0.6804	0.7603	0.7081	0.5727	0.7359	0.6865
Focal Loss (gamma=1)	0.6901	0.7450	0.6800	0.5071	0.7460	0.6258
Focal Loss (gamma=2)	0.6959	0.7494	0.6895	0.5094	0.5284	0.8627
Weighting + Focal Loss $\gamma=2$	0.6907	0.7084	0.7397	0.5000	0.5733	0.8465
Smote total	0.6008	0.6804	0.6555	0.4667	0.5666	0.6151
smote partiel	0.6038	0.6938	0.6535	0.4641	0.5739	0.6122
ADAYSON TOTAL	0.5853	0.6676	0.6404	0.4480	0.5620	0.6034
ADASYN partiel	0.6013	0.6966	0.6509	0.4564	0.5693	0.6110D
BACK TRANSLATION20%	0.6655	0.7679	0.7101	0.5185	0.7357	0.6392
BACK TRANSLATION50%	0.6535	0.7587	0.7101	0.4916	0.7399	0.6226
BACK TRANSLATION100	0.6577	0.7470	0.7033	0.5227	0.7277	0.6303

CHAPITRE 4 :Discussion

Analyse critique des résultats

Les expérimentations menées montrent que les stratégies de **modification de la fonction de perte** (Class Weighting, Focal Loss $\gamma=1$ et $\gamma=2$) sont globalement plus efficaces que les approches de **rééquilibrage par sur-échantillonnage** (SMOTE, ADASYN, Back Translation).

- **Focal Loss $\gamma=2$** se distingue par un **G-mean très élevé (0.8627)**, traduisant une meilleure homogénéité entre les classes, même si le F1 de la classe Neutral reste faible.
- **Class Weighting** améliore légèrement le F1 de la classe minoritaire Neutral (+0.044 par rapport au baseline), mais au prix d'une baisse du F1 de la classe Negative.
- **Les méthodes de sur-échantillonnage** (SMOTE, ADASYN) dégradent systématiquement les performances globales : F1-macro, AUC-PR et G-mean chutent, confirmant que les données synthétiques introduisent du bruit et réduisent la capacité de généralisation du modèle.
- **Back Translation** enrichit la diversité linguistique mais n'améliore pas significativement la classe Neutral, ce qui limite son intérêt comme solution principale.

En résumé, les résultats confirment que **les stratégies basées sur la fonction de perte sont plus adaptées au corpus TWIFL** que les méthodes de génération artificielle de données.

Limites méthodologiques

Plusieurs limites doivent être soulignées :

- **Classe Neutral persistante** : malgré toutes les stratégies, cette classe reste la plus difficile à modéliser. Cela peut être lié à une ambiguïté intrinsèque dans l'annotation ou à une faible représentativité dans le corpus.
- **Sur-apprentissage** : les courbes de validation montrent parfois une divergence entre entraînement et validation, surtout avec les rééquilibrages totaux. Cela traduit un risque de sur-apprentissage dû à la sur-représentation artificielle des minoritaires.
- **Qualité des données synthétiques** : SMOTE et ADASYN génèrent des vecteurs artificiels qui ne reflètent pas toujours la complexité linguistique du darija. De

même, Back Translation peut introduire des formulations artificielles ou non naturelles.

- **Corpus limité** : la taille et la diversité du corpus TWIFL influencent directement la robustesse des modèles. Les résultats pourraient évoluer avec un corpus plus large et mieux équilibré.

Spécificités du darija

Le darija (dialecte maghrébin) présente des particularités qui compliquent le traitement automatique

- **Code-switching** : alternance fréquente entre arabe dialectal, arabe standard et français, parfois dans une même phrase. Cela perturbe les modèles entraînés sur des données monolingues.
- **Orthographe non standardisée** : absence de norme d'écriture (arabe script vs latin script, variations phonétiques), ce qui augmente la variabilité des données.
- **Ressources limitées** : peu de corpus annotés disponibles, ce qui rend difficile l'entraînement de modèles robustes.
- **Ambiguïté sémantique** : certaines expressions du darija sont polysémiques ou contextuelles, ce qui complique la classification automatique.
- **Influence sociolinguistique** : le darija est fortement marqué par des emprunts culturels et linguistiques, ce qui rend la tâche de modélisation plus complexe que pour des langues standardisées.

Conclusion critique

- Les résultats montrent que **modifier la fonction de perte est plus efficace que générer des données artificielles**.
- Le **darija** pose des défis spécifiques liés à sa variabilité linguistique et au manque de ressources.
- Les limites observées (classe Neutral persistante, sur-apprentissage, bruit des données synthétiques) invitent à explorer des approches hybrides : combiner **pondération des classes, focalisation, et pré-entraînement sur des corpus multilingues**.
- Enfin, une meilleure **annotation du corpus** et une **standardisation partielle de l'écriture du darija** pourraient améliorer la qualité des modèles.

Conclusion générale

Ce projet a permis d'examiner en profondeur le **déséquilibre de classes** dans l'analyse de sentiments appliquée au dialecte algérien (darija), en utilisant le corpus **TWIFL** et le modèle **DziriBERT**. L'étude a montré que le modèle baseline est performant sur la classe majoritaire (*Positive*), mais reste fragile sur les classes minoritaires, en particulier *Neutral*.

Les différentes stratégies testées ont mis en évidence deux grandes approches :

- Les méthodes **basées sur la fonction de perte** (Class Weighting, Focal Loss) corrigent partiellement le biais, mais leur impact reste limité et peut parfois dégrader la stabilité de la classe majoritaire.
- Les méthodes **basées sur les données** (SMOTE, ADASYN, Back-Translation) se sont révélées plus efficaces. En particulier, **SMOTE partiel** et **Back-Translation** ont permis d'améliorer l'équilibre entre classes tout en maintenant une bonne robustesse globale du modèle.

Ces résultats confirment que l'**enrichissement des données** constitue la solution la plus prometteuse pour améliorer la détection des classes minoritaires dans le darija. La diversité lexicale et syntaxique apportée par les techniques d'augmentation contribue à renforcer la capacité du modèle à généraliser sur des exemples rares ou difficiles. Ce travail met également en évidence les défis spécifiques liés au dialecte algérien : variabilité orthographique, code-switching, usage de l'Arabizi et présence d'emojis, qui compliquent la tâche de classification automatique.

Perspectives

À la lumière des résultats obtenus et des limites identifiées, plusieurs pistes de recherche et d'amélioration peuvent être envisagées pour la suite du projet :

1. Amélioration des données et du corpus

- **Enrichissement du corpus TWIFL** : collecter davantage de données annotées, notamment pour la classe **Neutral**, afin de réduire son sous-représentativité.
- **Standardisation partielle du darija écrit** : proposer des conventions d'annotation et d'écriture pour limiter la variabilité orthographique (script arabe vs latin, translittérations diverses).
- **Annotation plus fine** : intégrer des sous-catégories de sentiments ou des métadonnées contextuelles (registre, intensité, code-switching) pour mieux capturer la complexité du darija.

2. Approches méthodologiques

- **Modèles multilingues pré-entraînés** : exploiter des modèles comme mBERT, XLM-R ou des variantes adaptées au dialecte arabe pour bénéficier de transferts inter-langues.
- **Apprentissage semi-supervisé** : utiliser des données non annotées pour renforcer les représentations, via des techniques comme pseudo-labelling ou consistency training.

3. Analyse linguistique et spécificités du darija

- **Étudier le code-switching** : développer des modèles capables de gérer l'alternance entre darija, arabe standard et français.
- **Intégrer des embeddings spécifiques au darija** : entraîner des représentations lexicales adaptées au dialecte pour réduire les confusions liées aux variations orthographiques.

4. Perspectives applicatives

- **Outils de monitoring des réseaux sociaux** : appliquer ces modèles pour analyser les sentiments exprimés en darija dans des contextes politiques, sociaux ou commerciaux.
- **Applications pédagogiques** : contribuer à la normalisation et à la valorisation du darija en développant des ressources linguistiques et des outils de traitement automatique.

